湖南科技大学
Hunan University of Science and Technology

第3章 机器学习

主讲人：康国胜
电　话：18202105624
Email：guoshengkang@gmail.com
个人主页：https://guoshengkang.github.io
实验室主页：https://intelligentservicelab.github.io
办公室：逸夫楼659





3.1 机器学习概述
3.2 机器学习分类
3.3 经典机器学习算法

湖南科技大学
Hunan University of Science and Technology

3.1 机器学习概述

3.1.1机器学习的概念

3.1.2 机器学习的流程

3.1.3 机器学习的评估与性能调优

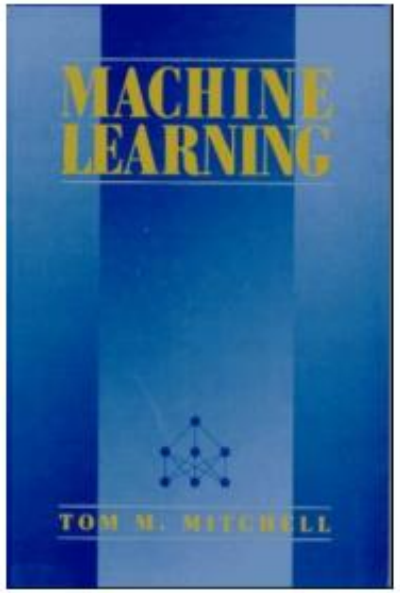


什么是机器学习

- 人工智能的一个分支
  - 数据 + 算法 → 训练生成模型
  - 识别规律，实现预测与决策

- 多领域交叉学科
  - 数学
    - 概率论
    - 矩阵论
    - 统计学
    - .....
  - 心理学
  - 脑科学
  - 哲学







汤姆·米切尔及其著作

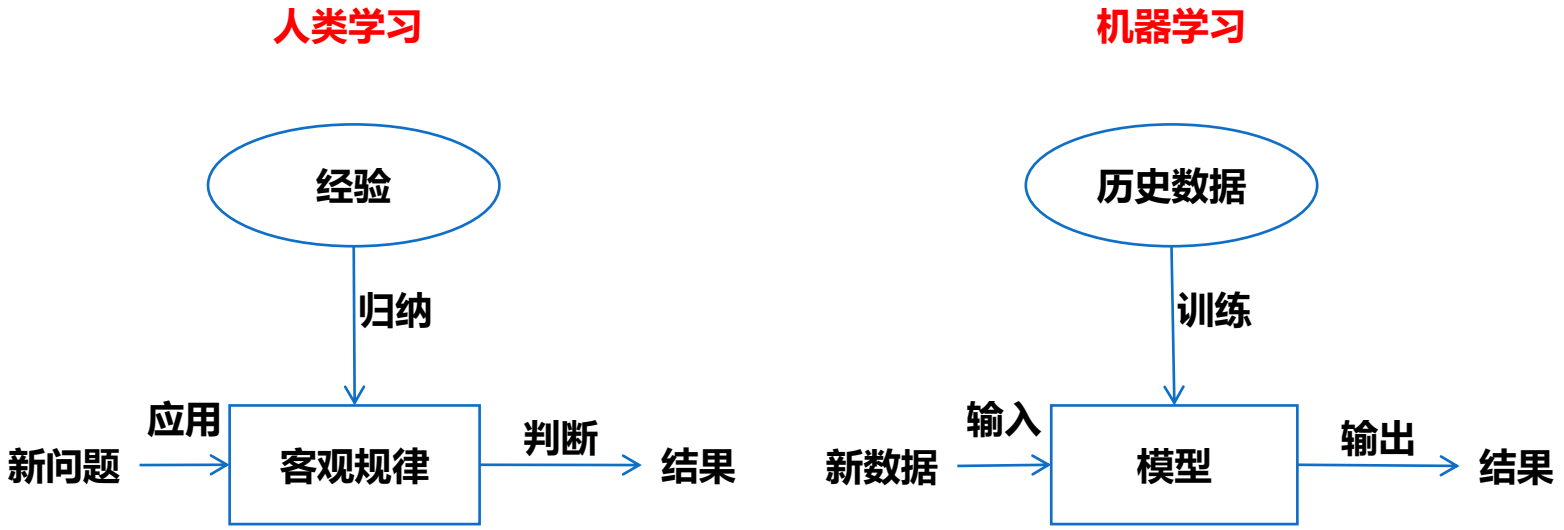
机器学习定义

- 暂无统一定义

- 经典著作《Machine Learning》定义：若一个计算机程序在任务类别T中的性能表现(通过性能度量P评估)随着经验E的积累而提升，则称该程序能够从经验E中学习。
  - **任务**(T)：机器学习的目标，即计算机需要完成的特定任务。例如，图像分类、语音识别、垃圾邮件检测等。
  - **经验**(E)：通过数据积累的经验，例如训练数据集中的标注图片或文本。
  - **性能度量**(P)：用于评估模型效果的指标，例如分类任务中的准确率或回归任务中的均方误差。

3.1.1机器学习的概念

机器学习与人类学习方式对比



3.1.1机器学习的概念

小朋友的学习过程



3.1.1机器学习的概念

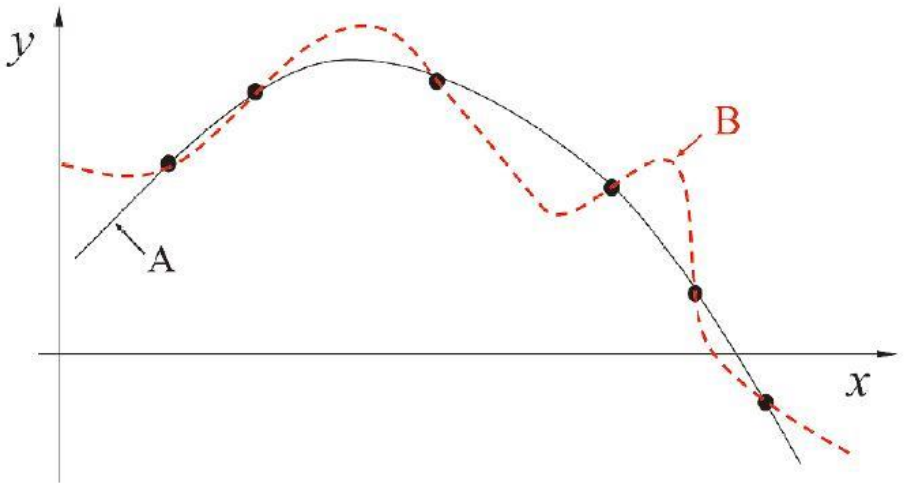
机器学习两条重要理论

- **奥卡姆剃刀原则** (Occam's Razor)
  - 如无必要，勿增实体
  - 例如：选取尖耳朵、长胡须、喵喵叫特征，而非耳朵曲率、胡须数量、叫声频率

- **没有免费午餐定理** (No Free Lunch, NFL)
  - 没有任何算法可以在所有可能的问题上始终优于其他算法，算法的性能在所有可能任务上平均是相同的
  - 例如：“识猫专家”小朋友比其他小朋友花更多代价识别狗

3.1.1机器学习的概念

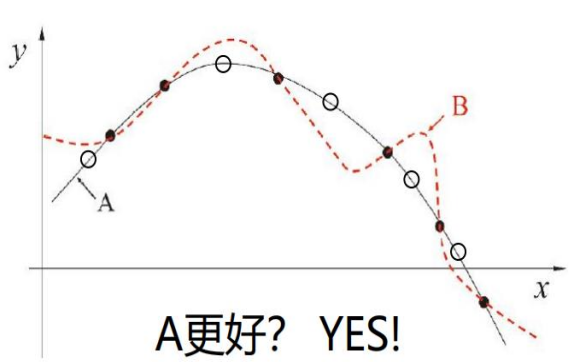
奥卡姆剃刀和NFL定理



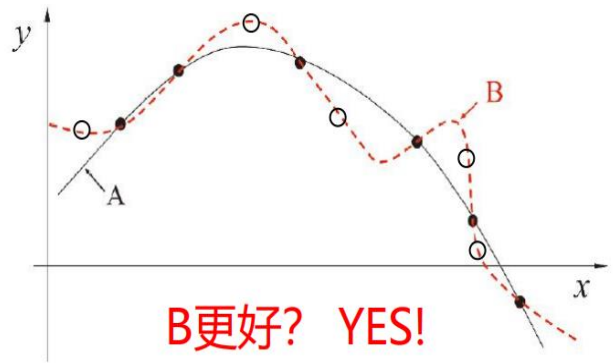
A还是B?

如无必要，勿增实体

黑点为训练样本，白点为测试样本



A更好？ YES!



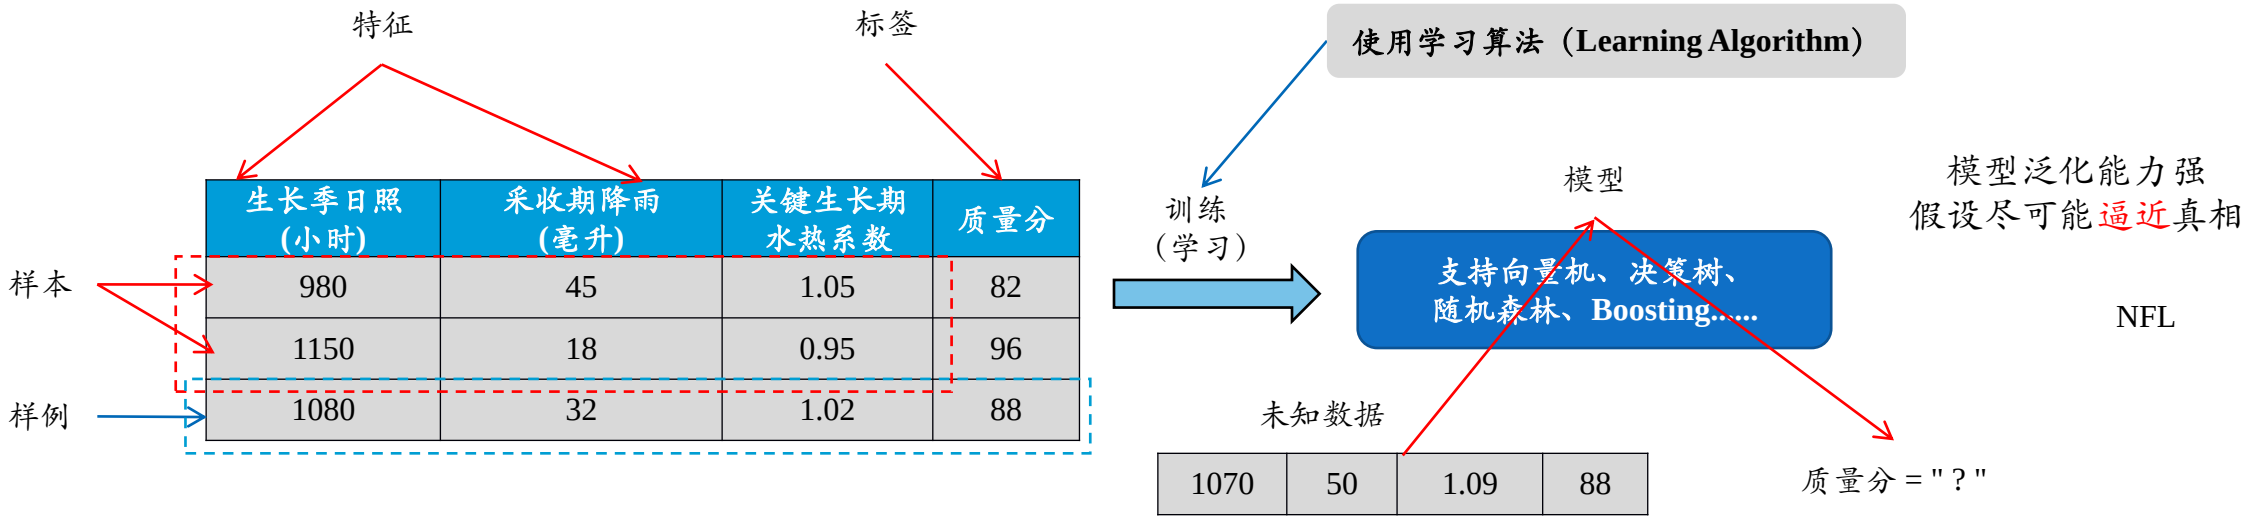
B更好？ YES!

算法A若在某些问题上比另一个算法B好，必存在另一些问题， B比A好

3.1 机器学习概述

3.1.2 机器学习的流程

基本概念



- 数据集(Data Set)、训练集、测试集
- 样本(Sample)或示例(Instance)
- 特征(Feature)或属性(Attribute)
- 特征空间(Feature Space) 或输入空间(Input Space)
- 标签空间(Label Space)或输出空间(Output Space)
- 特征值(Feature Value)、特征向量(Feature Vector)

- 假设(Hypothesis)：模型得到的质量分与各特征之间的映射关系
- 真相(Ground-Truth)：现实中质量分与各特征之间的客观规律

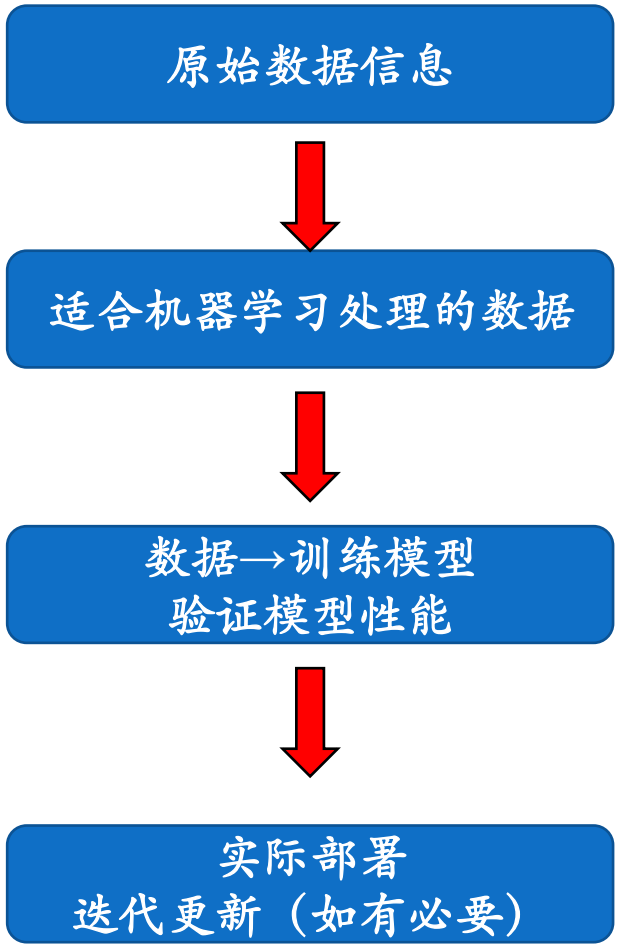
- 未知数据（Unseen Sample）：实际需要处理的数据
- 泛化（Generalization）能力：正确处理未知数据的能力

3.1.2 机器学习的流程

- **数据采集及预处理**
  - 原始数据收集
  - 数据预处理：标准化、向量化

- **模型训练与验证**
  - 假设→训练（学习）得到模型
  - 真相→判断假设是否符合或接近客观规律

- **模型部署与应用**
  - 理论模型→实际应用
  - 工程化



3.1.2 机器学习的流程

某葡萄酒产区近20年环境数据信息

年份	生长季日照(小时)	采收期降雨(毫升)	关键生长期水热系数	质量分
2004	980	45	1.05	82
2005	1150	18	0.95	96
2006	1080	32	1.02	88
2007	1050	60	1.10	85
2008	990	55	1.12	86
2009	1220	22	0.90	98
2010	1180	25	0.98	97
2011	1100	40	1.00	87
2012	900	65	1.25	78
2013	950	70	1.28	80
2014	1060	38	1.08	90
2015	1200	20	0.92	95
2016	1120	30	1.03	94
2017	1160	15	0.88	89
2018	1250	28	0.93	96
2019	1230	12	0.87	95
2020	1210	35	0.96	93
2021	940	58	1.30	83
2022	1280	10	0.85	97
2023	1150	42	1.01	91
2024	1070	50	1.09	88

产区环境数据历史信息

↓

筛选合适特征，得到关键数据（水热系数）

↓

训练样本数据得到标签（质量分），与当年实际葡萄质量进行比较判断

↓

收集2026年数据，利用模型判断当年葡萄质量，指导葡萄酒生产

3.1.3 机器学习的评估与性能调优

机器学习的评估与性能调优

- 模型评估
  - 泛化误差与训练误差
  - 精准率与召回率

- 模型优化
  - 过拟合及其缓解策略

3.1.3 机器学习的评估与性能调优

泛化误差与训练误差

- 训练误差
  - 训练集上产生的误差（经验误差）
  - 获取时间早，指导优化方向
  - 并非越小越好（过拟合）

- 泛化误差
  - 未知数据的输出结果与“真相”的误差
  - 获取时间晚，评价模型优劣
  - 越小越好

3.1.3 机器学习的评估与性能调优

评估指标

- **准确率 (Accuracy)**
  - 正确判断样本与实际标签的成功率
  - 例如：医生诊断疑似患者共100名，判断正确的比例是多少？
- **精准率 (Precission)**
  - 即查准率，预测优质样本中真实优质样本的占比
  - 例如：医生诊断出20名患者，确诊为病人的比例是多少？
- **召回率 (Recall)**
  - 即查全率，所有真实优质样本中被模型正确识别的占比
  - 例如：100疑似患者中有80名病人，医生诊断成功的比例是多少？

3.1.3 机器学习的评估与性能调优

示例

- 测试集中普通葡萄酒与优质葡萄酒的样本比例为9：1，即每10瓶酒中仅有1瓶为优质酒
  - 假设模型A判断葡萄酒为普通酒的准确率是65%
  - 模型B始终预测为普通葡萄酒，则准确率可达90%

- 模型A性能不佳，模型B性能好吗
  - 模型B召回率为0，难以部署在实际场景下，使得精准率也失去意义
  - 类别不平衡时，准确率不能单独判断模型好坏

3.1.3 机器学习的评估与性能调优

精准率与召回率

模型C

$$精确率\ P = \frac{TP}{TP + FP}$$

$$召回率\ R = \frac{TP}{TP + FN}$$

	预测优质酒	预测普通酒	合计
现实优质酒	TP = 22	FN = 78	100
现实普通酒	FP = 49	TN = 851	900
合计	71	929	1000

模型C预测优质酒的精确率0.31，召回率0.22，性能较差

3.1.3 机器学习的评估与性能调优

综合数值—F1 值

- F1 值是精准率与召回率的调和平均数，可以引入权重调节系数β
  - 当$\beta = 1$时，精准率和召回率的权重相等，F_β等同于标准F1值；
  - 若侧重精准率，则减小β
  - 若侧重召回率，则增大β

$$\frac{1}{F1} = \frac{1}{2} \times \left(\frac{1}{P} + \frac{1}{R}\right) \qquad \mathrm{F1} = \frac{2PR}{P+R}$$

$$F_\beta = (1+\beta^2)\frac{PR}{\beta^2 P + R}$$

3.1.3 机器学习的评估与性能调优

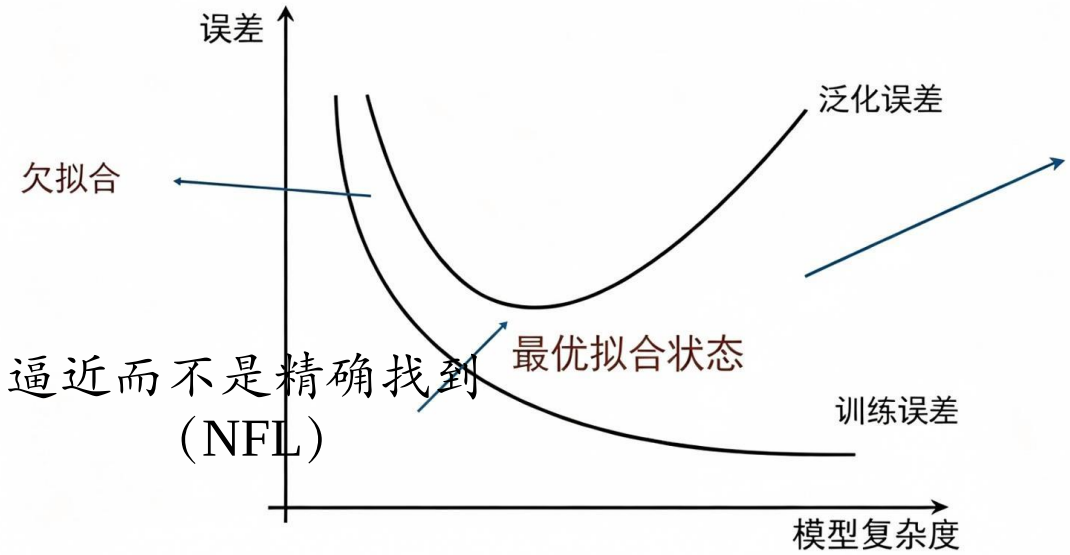
过拟合及其缓解策略

- 过拟合
  - 训练误差低，泛化误差高
  - 训练过度，将训练集中的噪声也“学习”进模型，白马才是马

- 欠拟合
  - 训练误差高，泛化误差高
  - 训练不足，没有将训练集的特征学习完毕，牛也是马

3.1.3 机器学习的评估与性能调优

过拟合与欠拟合误差变化趋势示意图



逼近而不是精确找到
(NFL)

过拟合是机器学习中最常见也最隐蔽的失效诱因，是所有机器学习任务都必须直面并解决的问题

三段区间：

1.在左侧区间内，模型的拟合能力不足，无法充分学习训练数据的内在规律(欠拟合)；

2.中间拐点对应模型的最优拟合状态；

3.在右侧区间内，模型的拟合能力过剩，过度学习训练数据中的随机噪声，导致模型在未知数据上预测效果较差(过拟合)。

3.1.3 机器学习的评估与性能调优

如何缓解过拟合

- **特征选择**
  - 正则化等技术手段对模型进行特征精简，对冗余特征施加约束并降低其权重贡献，如无必要，勿增实体
- **交叉验证**
  - 时间序列交叉验证，多次检验模型泛化效果，输出结果更加稳健可靠
- **早停**
  - 实时监测泛化误差并控制训练迭代轮次
- **数据增强**
  - 扩充样本规模
- **集成学习**
  - 采用多个和而不同的学习模型（具体见3.3.5随机森林）

3.1.3 机器学习的评估与性能调优

机器学习的评估与性能调优

- 机器学习模型评估的核心并非确定单一数值，而是在模型拟合能力上限与业务风险偏好之间构建可量化、可调整的评价体系

- 机器学习模型的性能评判标准需要结合应用场景、业务需求、实施成本等要素综合考量，无论是不计成本地提升模型的泛化性能，还是在限定成本范围内达到预期效果，均需要结合实际场景进行判定

- 机器学习模型评估的最终目标并非单纯追求各项指标数值最优，而是为业务提供更合理的决策依据

湖南科技大学
Hunan University of Science and Technology



3.2 机器学习分类

3.2.1监督学习

3.2.2无监督学习

3.2.3强化学习

机器学习与传统编程的本质差异

- 传统编程
  - 输入规则→输出结果
  - 例如：温度高于30℃，开启空调

- 机器学习
  - 输入数据→训练模型→预测结果
  - 数据特征（属性）与目标变量（标签）的不同关联方式
    - 监督学习：温度数值对应空调开关状态
    - 无监督学习：有大量温度记录却没有对应空调开启状态
    - 强化学习：空调系统根据用户舒适度评分调整策略

3.2.1 监督学习

监督学习

- 应用最广泛的方法之一
  - 带标签的数据训练模型
  - 学习特征到标签的映射关系
  - 对未知数据进行预测

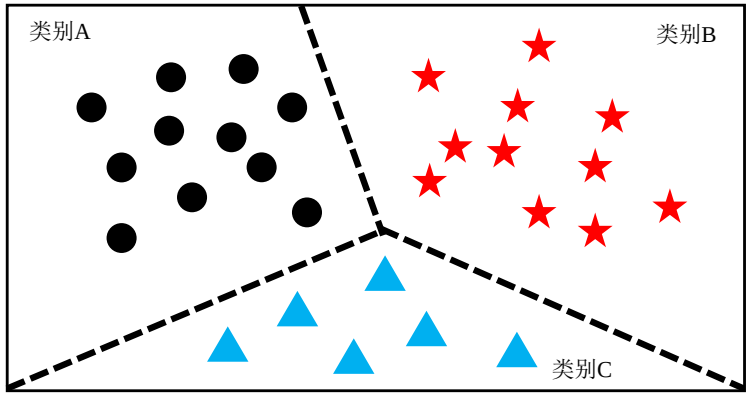
- 预测的目标值
  - 分类：预测结果为离散值，例如学生考查课成绩、明天是否下雨等
  - 回归：预测结果为连续值，例如学生考试成绩、股票价格等

3.2.1 监督学习

分类任务

- **方法**：从带标签的历史数据中学习映射规律

- **目标**：对未知样本赋予离散类别标签
  - 无序标签：水果分类（苹果、梨）
  - 有序标签：成绩分类（优良中差）



多分类示意图

- **类别**：
  - 二分类（判断是否违规）
  - 多分类（花卉品种识别）

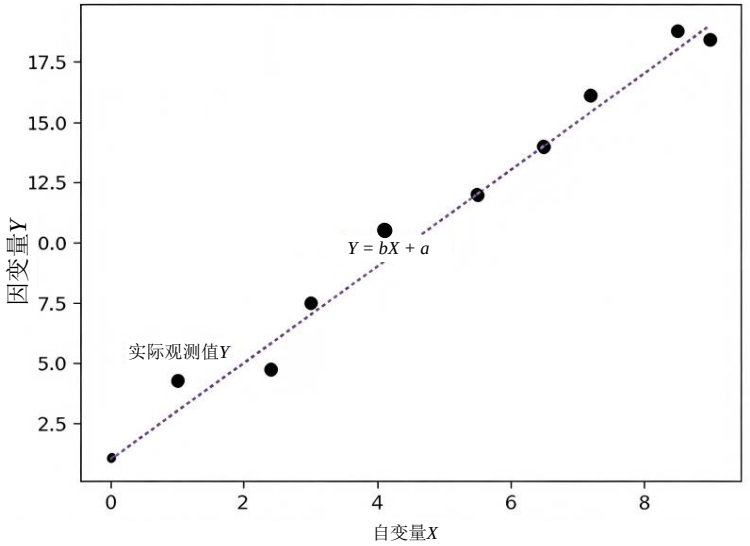
3.2.1 监督学习

回归任务

- **方法**：从带标签的历史数据中学习映射规律

- **目标**：对未知样本赋予连续数值
  - 数值意味着有“距离”，差值含义明确

- **类别**：
  - 一元回归：通过单个输入特征预测
  - 多元回归：通过多个输入特征预测



线性回归示意图

3.2.2无监督学习

无监督学习

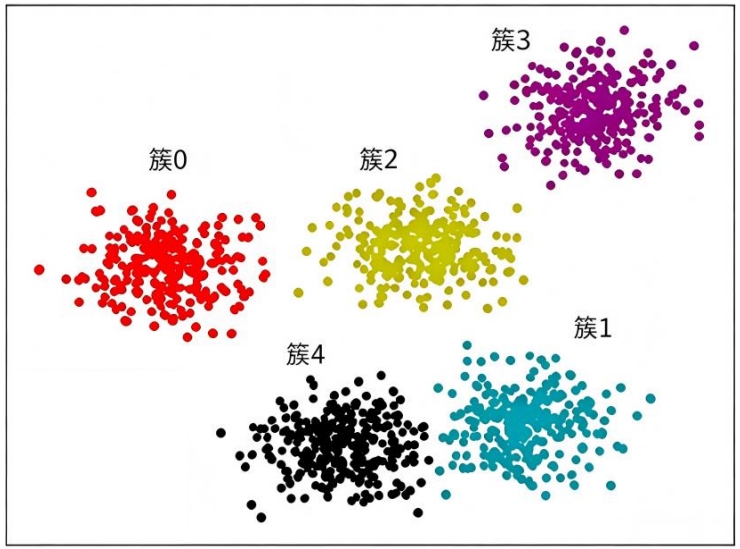
- 常见方法之一
  - 历史数据集无标准输出标签
  - 识别样本之间的相似性与差异性
  - 对未知数据进行探索

- 探索未知数据
  - 聚类：用户画像
  - 降维：图片压缩
  - 异常检测：飞机安检

3.2.2无监督学习

聚类

- **方法**：将特征相近的样本自动归为同一簇
  - 模型本身无法知晓各簇对应的含义
- **目标**：仅依据特征距离或样本密度对样本进行同类划分。
- **示例**：电商平台根据用户行为数据将海量用户划分为若干消费群体，各群体对应的特征由运营人员后续解读。



聚类示意图

3.2.2无监督学习

降维

- **方法**：筛选信息，提取有效信息
- **目标**：将高维数据映射至低维空间，同时尽可能保留原始信息
- **示例**：降维算法，确定数据方差最大的方向，将其定义为第一主成分；再选取与第一主成分正交且方差次大的方向作为第二主成分；以此类推，直至损失量达到阈值或者任务达标

3.2.2无监督学习

异常检测

- **方法**：学习正常样本的分布特征，新样本与模型习得的正常分布偏离程度越高，被判定为异常样本的概率越高

- **目标**：识别与多数样本存在明显偏差的离群样本

- **示例**：安检人员没有统一明确的异常判定标准，也无法浏览全部违禁品样本图像，在长期观测正常行李的X光影像后，便可快速识别并拦截刀具、高压罐体等物品

- **异常样本特点**
  - 极其稀少、采集成本高、无法完整枚举等

3.2.3 强化学习

强化学习

- 强化学习 (Reinforcement Learning，RL) 同样是机器学习中的一类重要方法，依托环境反馈持续试错迭代，是追求长期累积奖励最大化的动态学习过程



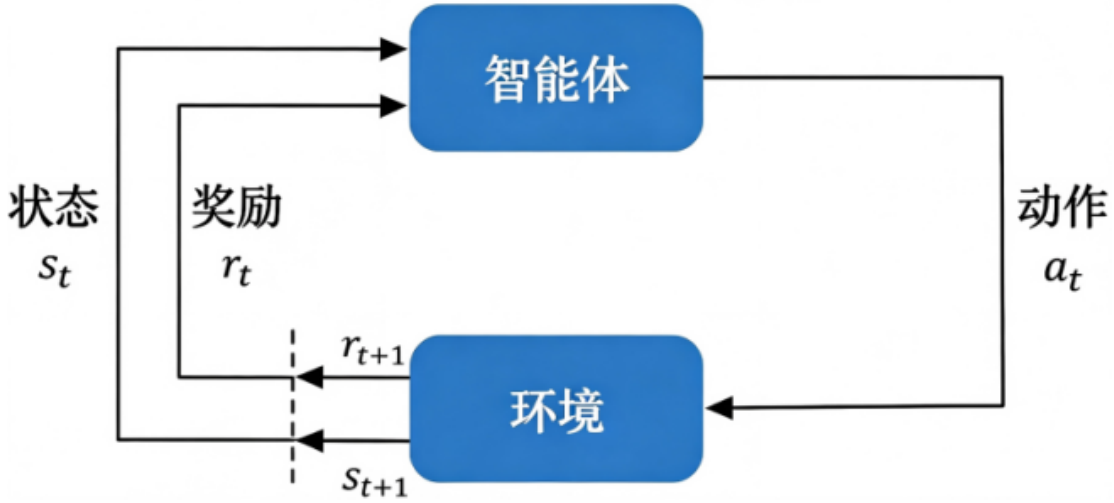
小狗学习“坐下”指令

3.2.3 强化学习

强化学习建模

- 马尔可夫决策过程 (Markov Decision Process，MDP)
  - 状态空间
  - 动作空间
  - 状态转移概率
  - 奖励函数
  - 折扣因子

Ref. P86



马尔可夫决策过程示意图

湖南科技大学
Hunan University of Science and Technology



3.3 经典机器学习算法

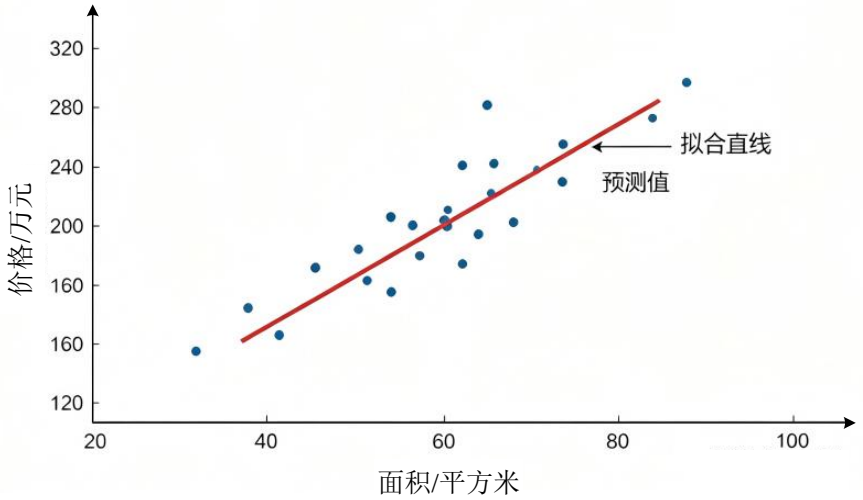


- 3.3.1 线性回归
- 3.3.2 支持向量机
- 3.3.3 决策树
- 3.3.4 朴素贝叶斯
- 3.3.5 随机森林
- 3.3.6 AdaBoost
- 3.3.7 K均值聚类

3.3.1线性回归

引例——线性回归算法

- 假设一位刚入行的房产中介，手里有一张表格，一列为房屋面积，另一列为成交价格。他想为客户预估合理的成交价格，便将数据点绘制在坐标系中，横轴代表房屋面积，纵轴代表成交价格。随后他拿出一把透明尺子，在数据点之间反复比对，试图找到一条能够最优拟合整体数据分布的直线。直线确定后，对于一套80平方米的房屋，沿横轴找到对应的面积数值，再确定该数值在直线对应的点，即可得出对应的预估成交价格约为240万元。



线性回归示意图

3.3.1线性回归

线性回归算法

- 机器学习中最古老、最基础的监督学习算法，假设目标变量(因变量)与特征变量(自变量)之间存在近似线性相关关系，求解最能拟合数据整体变化趋势的直线(或高维空间中的超平面)，并利用该模型预测未知样本的连续数值。

3.3.1线性回归

基本概念

- **一元线性回归**
  - 预测值仅与一个特征之间存在近似线性相关关系，公式3-6
- **多元线性回归**
  - 特征数量大于1，预测值与多个特征之间存在近似线性相关关系，公式3-7
- **误差**
  - 误差为预测值与真实值的差值，公式3-8
- **损失函数**
  - 损失函数用于量化单个样本或整体误差大小，最常用的为均方误差(Mean Squared Error，MSE)，公式3-9
  - 避免正负误差相互抵消
  - 对偏离程度较大的样本施加更大的惩罚权重

3.3.1线性回归

求解方法

- **最小二乘法**可直接求解最优参数
  - 对MSE损失函数的w和b分别求偏导，并令偏导数为零
  - 联立并求解方程组即可得到最优参数
  - 求解速度快、精度高，但难以处理特征数量大于样本数量场景

- **梯度下降法**
  - 沿损失函数梯度的负方向小幅更新参数
  - 多次迭代逐步收敛至最优解
  - 适用于大规模数据集与高维特征场景，设置的学习率不宜过大或过小

3.3.1线性回归

实现步骤

- 数据准备与预处理
  - 填充缺失值
  - 剔除异常值
  - 特征标准化
- 划分数据集
  - 划分为互不相交的训练集、验证集、测试集
- 求解模型参数
- 完成模型评估与迭代优化

3.3.1线性回归

优势与局限性

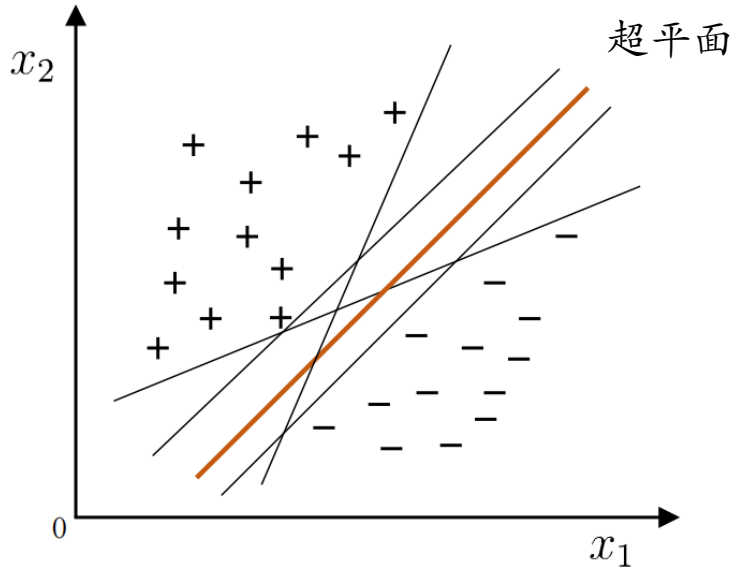
- 优点
  - 可解释性强
  - 计算效率高
  - 理论基础扎实
  - 可作为基线模型

- 缺点
  - 仅能拟合输入与输出间的线性组合关系
  - 对异常值敏感
  - 受多重共线性影响大

3.3.2 支持向量机

支持向量机算法

- 基于统计学习理论的监督学习模型，广泛应用于分类与回归任务
- 核心思想是在线性可分场景下，直接在原始特征空间中求解最优分隔超平面；针对线性不可分样本，通过非线性映射，将原始空间内的输入向量映射至高维特征空间，并在该高维空间内求解最优分隔超平面，实现不同类别数据的有效区分
- SVM就是在不同类别的数据点之间，寻找间隔尽可能宽的间隔带作为分类边界



“正中间”的: 鲁棒性最好, 泛化能力最强

支持向量机示意图

3.3.2 支持向量机

基本概念

- **超平面**
  - 在二维空间中是一条**直线**，在三维空间中是一个**平面**，在四维及更高维度空间中称为**超平面**，其作用是分隔正负两类样本
- **间隔**
  - 间隔是指两个平行边界超平面之间的**垂直距离**，SVM中的优化目标为最大化间隔
- **最大间隔超平面**
  - 在所有能够正确分隔两类样本的候选超平面中，可使间隔达到最大的超平面即为最大间隔超平面，图中正中间的线
- **支持向量 (Support Vector)**
  - 落在间隔边界上的样本（图中红色虚线）即为支持向量，它们是决定分隔超平面位置的关键参数
- **核函数**
  - 当数据在原始空间中线性不可分时，SVM通过核函数将数据映射至更高维空间，使数据在新空间内实现线性可分

3.3.2 支持向量机

求解方法

- SVM的求解本质上是一个凸二次规划问题，其目标是最大化间隔。对于线性可分数据，SVM需要找到能够将两类样本完全分开且间隔最大的超平面。间隔的大小与超平面的法向量长度成反比。法向量越短，间隔越宽。因此，SVM在确保所有样本均被正确分类的前提下，使法向量尽可能短，从而找到具有最强泛化能力的决策超平面。

- 由于直接求解原始优化问题较复杂，通常采用拉格朗日乘数法并结合对偶理论将原始优化问题转化为更易于求解的对偶问题。在求解过程中，仅支持向量对应的拉格朗日乘子取值非零，其余样本对应的乘子全部为零，这也是SVM“决策边界仅由少数支持向量决定”的数学依据。

3.3.2 支持向量机

实现步骤

- 数据准备与预处理
  - 收集带标签的训练样本，将原始数据转换为数值特征
- 选择核函数
  - 线性核适用于线性可分场景
  - 高斯核适用于数据分布复杂、边界非线性的场景
- 训练模型
  - 求解凸二次规划问题，可由序列最小优化算法 (Sequential Minimal Optimization，SMO)等优化算法自动完成
- 模型评估与优化
- 部署应用

3.3.2 支持向量机

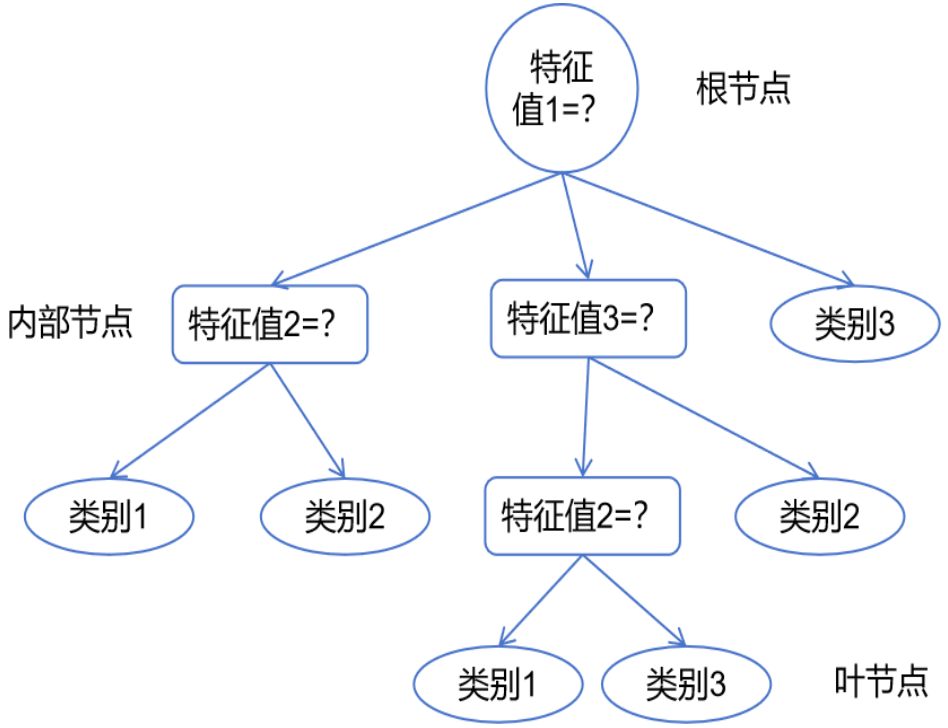
优势与局限性

- 优点
  - 泛化能力良好，模型不易发生过拟合，理论基础扎实。
  - 核技巧使SVM可以构建较为复杂的分类边界，具备较强的非线性数据处理能力。
  - 模型训练完成后仅依赖少量支持向量，存储效率高且预测速度快。
  - 对远离分类边界的样本不敏感，模型决策边界仅由支持向量决定，鲁棒性较好。
- 缺点
  - 传统SVM的计算复杂度会随样本量增大急剧上升。
  - 作为二分类器，SVM对多分类问题的原生支持能力较弱。
  - SVM对核函数与超参数的选择较为敏感。

3.3.3 决策树

决策树算法

- 是机器学习中最接近人类思维方式的算法。
- 通过逐层判断、逐步筛选，最终将样本划分至对应叶子节点并输出决策结果。
- 该过程具备较高的可解释性，研究者可绘制决策树结构，依据各分支的判断条件说明样本的分类原因。



决策树示意图

3.3.3 决策树

基本概念

- 根节点
  - 决策树的起点，包含全部训练样本，首次特征判断在此处进行
- 内部节点
  - 针对某一特征进行判定，并将样本划分至不同分支
- 分支
  - 代表特征单一取值或取值区间，将样本由父节点传递至子节点
- 叶节点
  - 决策树的终点，不再进行特征判定，直接输出对应分类标签或预测数值作为结果
- 纯度
  - 节点内部样本的类别统一程度，节点内全部为同类样本时纯度为100%

3.3.3 决策树

求解方法

- 决策树构建过程的核心思想是递归式“分而治之”。在建树过程中，算法从根节点出发，遍历所有候选特征，计算按每个特征划分后子节点的纯度提升幅度，选择提升幅度最大的特征作为当前节点的分裂特征，将样本分配至各子节点
- 该过程在子节点上递归执行，直至满足以下**三种停止条件**之一，当前节点便成为叶节点并标注对应类别或数值
  - 节点内样本全部属于同一类别，即纯度达到 100%
  - 节点内无样本，该叶节点的类别由其父节点确定
  - 全部特征均已完成分裂，无法继续向下生长，该叶节点的类别由当前节点内占多数的样本确定
- 衡量**节点纯度**的主流指标共有三种
  - **信息增益**：ID3算法采用，该指标倾向于选择取值较多的特征
  - **信息增益率**：C4.5算法采用，修正了信息增益存在的偏好问题
  - **基尼系数**：CART算法采用，是当前应用最广泛的决策树算法

3.3.3 决策树

实现步骤

- **数据准备**
  - 收集带标签的训练样本，决策树对缺失值具备一定容忍度，但仍需对缺失值开展适配处理，无需对特征执行标准化或归一化操作。
- **选择分裂准则**
  - 根据任务类型选取节点纯度度量指标，**分类任务**常采用基尼系数或信息增益，**回归任务**一般选用均方误差作为分裂准则。
- **训练模型**
  - 以根节点为起点，递归选取最优特征完成节点分裂，持续生长直至触发停止条件。
- **剪枝优化**
  - 针对完整生成的决策树执行后剪枝操作，自底向上评估各子树对验证集性能的提升效果，移除信息增益不明显的分支以增强模型泛化能力。
- **模型评估与部署**

3.3.3 决策树

优势与局限性

- 优点
  - 可解释性极强
  - 无需特征缩放
  - 擅长处理混合类型数据
  - 自动特征选择
  - 可处理非线性关系
  - 对异常值具备鲁棒性

- 缺点
  - 容易发生过拟合
  - 模型稳定性较差
  - 存在分裂准则偏好问题
  - 回归能力受限

3.3.4 朴素贝叶斯

- 想象收到一封陌生邮件，标题写着“恭喜您中奖了”，正文含有“免费”、“点击领取”、“紧急”等词汇，人们几乎会本能地断定这是一封垃圾邮件。这种直觉来源于过往经验：人们接触过大量具备同类特征的邮件，且这类邮件大多被标记为垃圾邮件，本质是基于历史经验完成概率判断。
- 朴素贝叶斯算法正是模仿该类判断逻辑的机器学习算法，其核心原理依托18世纪英国数学家托马斯·贝叶斯提出的贝叶斯定理：在已知部分特征(如邮件中出现“免费”一词)的条件下，计算对应事件(该邮件为垃圾邮件)的发生概率，算法最终选取概率最大的类别作为预测结果。“朴素”的含义源于算法采用的高度简化假设，即所有特征相互条件独立。在邮件分类场景中，该假设认为“免费”一词的出现与“中奖”一词的出现互不相关。该假设与实际数据分布并不完全相符，相关词汇往往会伴随出现，但正是这一简化假设大幅降低了计算复杂度，使算法在适配场景中具备优良性能。

3.3.4 朴素贝叶斯

基本概念

- **先验概率**
  - 指未参考任何特征时，对目标类别判定的基础概率
- **似然概率**
  - 指已知样本类别的前提下，对应特征出现的概率
- **后验概率**
  - 指在观测到样本特征后，该样本归属于某个类别的最终概率
- **贝叶斯定理**
  - 朴素贝叶斯算法的核心计算公式，该公式融合先验概率与似然概率，用于求解后验概率，公式3-10
- **拉普拉斯平滑**
  - 用于解决零概率问题

3.3.4 朴素贝叶斯求解方法

- 朴素贝叶斯算法在特征条件独立假设下的概率计算过程十分简洁

- 给定一封邮件，判断其属于类别C，假设类别包含C1垃圾邮件、C2官方邮件、C3私人邮件，分别计算数值D1、D2、D3：
  - P(垃圾邮件)·P(“免费”|垃圾邮件)·P(“中奖”|垃圾邮件)·P(“领取”|垃圾邮件)
  - P(官方邮件)·P(“免费”|官方邮件)·P(“中奖”|官方邮件)·P(“领取”|官方邮件)
  - P(私人邮件)·P(“免费”|私人邮件)·P(“中奖”|私人邮件)·P(“领取”|私人邮件)
  - P(XX邮件)为对应邮件类别的样本比例，P(词|XX邮件)为对应的邮件类别中该词出现的频率，选取最大结果

3.3.4 朴素贝叶斯

实现步骤

- **数据准备与预处理**
  - 收集带标签的文本样本，将连续文本切分为离散词汇单元，记录各词汇的出现状态或出现频次
- **统计概率参数**
  - 计算各类别的先验概率，得到各类别样本占全部样本的比例；再按类别统计各词汇的条件概率，即词汇在该类别全部邮件中的出现频率
- **模型存储**
- **新样本预测**
  - 对测试样本执行相同的分词与向量化处理，针对每一类候选类别求解后验概率；常规处理方式为取对数，将连乘运算转换为累加运算，防止数值下溢，选取后验概率最大的类别作为预测结果
- **模型评估**

3.3.4 朴素贝叶斯

优势与局限性

- 优点
  - 训练极其高效
  - 适配小规模数据集
  - 高维数据处理能力强
  - 可解释性强
- 缺点
  - 特征条件独立假设约束过强
  - 对未收录特征敏感
  - 无法学习特征交互关系
  - 对类别不平衡数据敏感
  - 处理连续数值特征的能力有限

3.3.5 随机森林

- 想象一位肿瘤科医生查看病理切片，需要判断病变属于良性还是恶性。若仅咨询一位专家，其可能因当日状态不佳、对部分病变亚型不熟悉或存在个人经验偏见产生误判；若同时邀请数十位专家独立阅片并投票表决，即便个别专家判断失误，整体结论依旧可靠。

- 随机森林正是沿用这一思路。它是由成百上千棵决策树构成的集成模型。每棵树基于自助采样得到的子样本、不同特征组合完成独立学习与预测判断，最终通过集体投票得到输出结果。单棵树带来的个体偏差会在投票过程中相互抵消，从而发挥群体决策优势。

3.3.5 随机森林

基本概念

- **决策树**
  - 决策树是随机森林的**基学习器**，随机森林并不要求单棵决策树具备最优性能，而需要数量充足、结构存在差异的决策树，每棵决策树分配互不相同的训练样本。
- **自助采样**
  - 随机森林训练的核心方法，从原始数据集中进行有放回随机抽样，会造成部分样本被多次抽取，另有部分样本完全未被抽中（约36.8%），该部分数据可直接用作验证集。
- **随机特征选择**
  - 除训练数据存在差异外，每棵决策树使用的特征也各不相同。
- **投票与平均**
  - 新样本输入随机森林后，每棵决策树独立输出样本类别，遵循少数服从多数规则，得票数最高的类别作为最终预测结果（分类），或者对全部预测值求取算术平均值（回归）。

3.3.5 随机森林

求解方法

- 核心思想—和而不同
  - 单棵决策树容易产生过拟合现象，且容易将训练集中的噪声、异常值、偶然规律作为划分依据，不执行剪枝操作，允许每棵决策树充分生长，提升各决策树之间的多样性，以此抵消模型误差带来的影响。

- 自助采样
  - 使每棵决策树仅使用约63.2%的原始样本，未被选取的样本可直接作为验证集。更为关键的是，每棵决策树缺失部分样本信息，难以产生一致性预测偏差。

- 单棵树的偏差基本保持不变，集成后整体方差则显著降低。
- 袋外数据(约36.8)是随机森林自带的验证数据集，因此训练随机森林时无须额外划分独立验证集。

3.3.5 随机森林

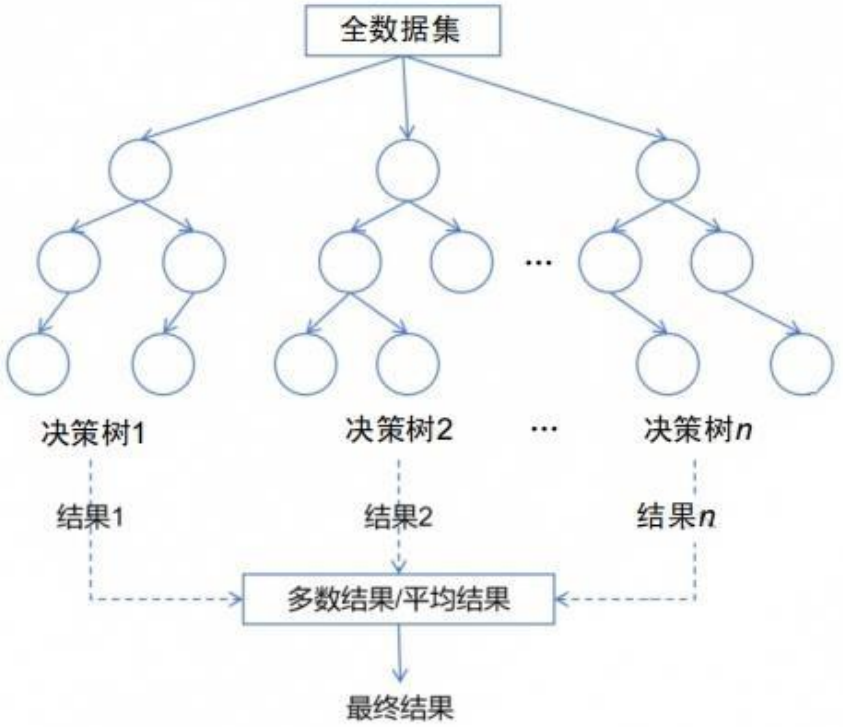
实现步骤

- **设定决策树的数量**
  - 决策树数量越多，模型性能越好，计算成本也越高，需权衡。
- **生成训练子集**
  - 原始训练集中通过自助采样生成同等规模的子数据集，不剪枝。
- **随机分裂**
  - 从全部特征里随机选取一部分作为候选特征，从中挑选最优切分点。
- **重复前两个步骤**
  - 直至随机森林中包含预设数量的决策树。
- **预测与集成**
  - 投票输出结果。

3.3.5 随机森林

优势和局限性

- 优点
  - 抗过拟合能力强
  - 对异常值不敏感
  - 适用于高维数据
  - 支持特征重要性评估
  - 调参成本低
  - 支持并行训练
- 缺点
  - 模型占用资源大
  - 可解释性较差
  - 易受冗余噪声特征干扰



随机森林示意图

3.3.6 AdaBoost

- AdaBoost算法同样属于**集成学习**的代表方法之一

- 与随机森林多决策树并行独立训练的方式不同，AdaBoost算法采用串行迭代训练，后续基学习器重点拟合前序基学习器错误分类的样本。

- 在每一轮迭代过程中，算法会动态调整样本权重，提高错分样本的权重、降低正确分类样本的权重，引导后续基学习器着重拟合难以区分的疑难样本。

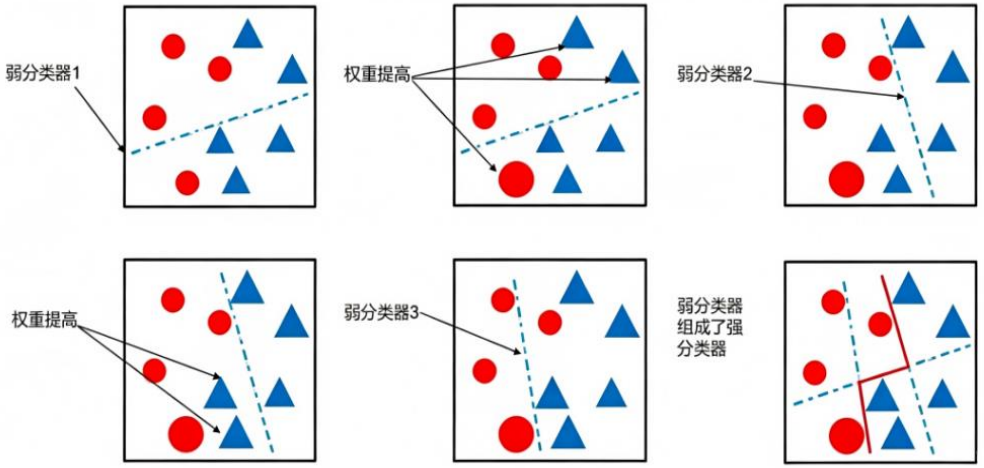
3.3.6 AdaBoost

基本概念

- **弱学习器**
  - AdaBoost算法对基学习器的要求极低，只要其分类准确率略高于50%(二分类问题中优于随机猜测)即可
- **样本权重**
  - 训练开始时，所有样本权重相等，每一轮训练结束后，被错分的样本权重提高，被正确分类的样本权重降低
- **学习器权重α**
  - 并非每个基学习器在最终投票中所占分量都相同，错误率越低，α越大，投票权重越大
- **串行训练**
  - 基学习器存在严格的先后顺序，后一个基学习器依赖前一个基学习器的训练结果

3.3.6 AdaBoost 求解方法

- 调整样本权重
  - 在每一轮训练结束后，算法都会更新样本权重分布，降低当前基学习器正确分类的样本权重，提高当前基学习器错误分类的样本权重，以此改变样本分布。
- 计算模型权重
  - 在每一轮训练结束后，根据当前基学习器的加权错误率ε_t计算其权重α，见公式3-11。
- 最终强学习器的输出是所有基学习器的加权和



AdaBoost算法示意图

3.3.6 AdaBoost 实现步骤

- **初始化样本权重**
  - 将所有训练样本的权重初始化为相等值训练基学习器
- **计算加权错误率与基学习器权重**
  - 在当前样本权重分布下，训练一个基分类器，使其在加权样本上的错误率尽可能低
- **更新样本权重**
  - 计算当前基学习器的加权错误率，再根据加权错误率计算该基学习器的投票权重α
- **迭代与集成**
  - 提高被当前基学习器错分的样本权重，降低被正确分类的样本权重，然后归一化所有样本权重使其之和为1
- **迭代与集成**
  - 重复上述3个步骤，直至达到预设的基学习器数量或满足迭代终止条件

3.3.6 AdaBoost 优势和局限性

- 优点
  - 预测精度高，多数场景下精度上限高于随机森林的精度
  - 简单易实现，默认参数通常就能取得不错效果
  - 每轮训练中会优先选出对当前加权样本区分效果最优的特征
  - 泛化性能优异、不易发生过拟合
  - 灵活性强，广泛搭配各类基学习器
- 缺点
  - 对噪声和异常值敏感
  - 串行结构限制
  - 对类别不平衡敏感
  - 对参数敏感，性能下限较低

3.3.7 K均值聚类

引例

- 假设一位果农刚摘了一批苹果，想按品质分成三堆售卖，但还没有具体的分级标准。他先随手从果堆中挑出三个苹果摆在桌上，作为三个等级的样品；接着拿起其他苹果，逐个对比，看颜色红不红、个头大不大、表面有没有斑痕，以判断与哪个样品最为相似，就归到该样品对应的果堆旁。第一轮分完后，每个等级都归集了部分苹果。果农再从每堆中选取能够代表该堆平均品质的苹果，替换原有样品；随后将全部苹果重新归集，依据新样品完成新一轮划分。多轮迭代后，三堆苹果的归类结果不再发生变化，分级完成。这个过程正是K均值聚类算法思想的直观呈现。



3.3.7 K均值聚类

基本概念

- **K值**
  - K是算法唯一需要用户事先指定的参数，它的选择通常依赖于业务需求或经验法则
- **簇**
  - 簇是被划分至同一组的数据点集合，同一簇内的样本彼此相似，不同簇之间的样本差异较大
- **质心**
  - 每个簇都存在一个中心点，为该簇内全部样本点的均值，仅代表一个虚拟坐标位置
- **距离**
  - 距离用于衡量样本与质心之间的差异程度，决定样本应被分配至哪一簇，最常用的度量为欧氏距离

3.3.7 K均值聚类

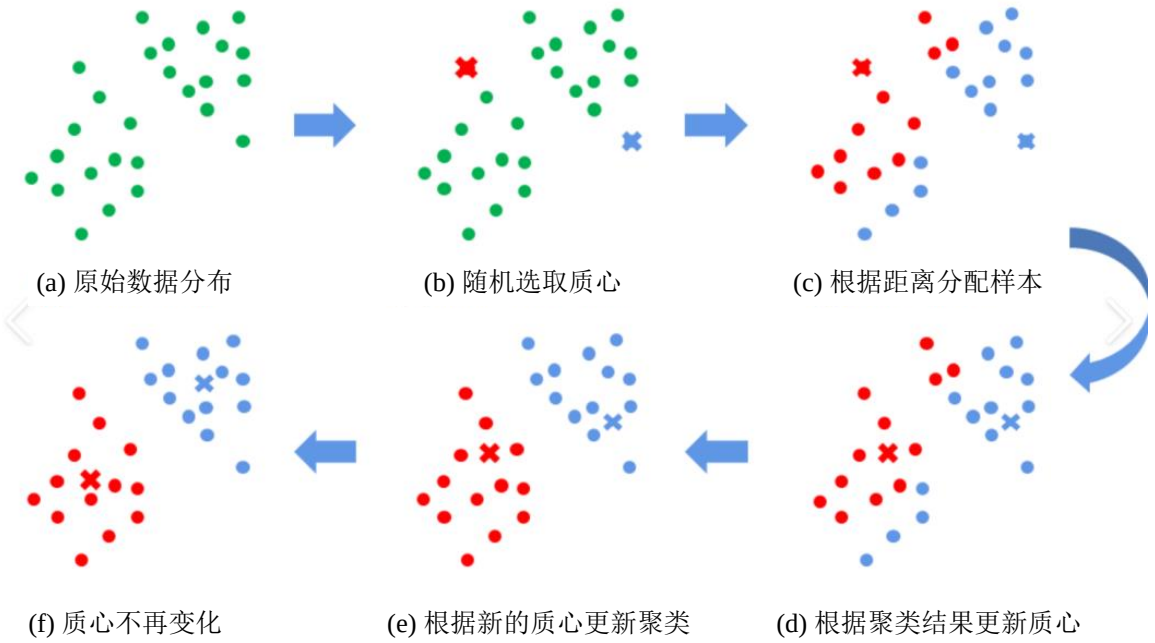
求解方法

- 选取K值
- 初始化质心
  - 随机选取K个样本完成质心初始化
- 分配样本
  - 计算每个样本到K个质心的距离，将样本划分至距离最近的质心所属簇
- 更新质心
  - 重新计算每个簇内所有样本的均值，以此作为该簇的新质心
- 迭代判断
  - 重复上述两个步骤，直至质心位置不再发生显著变化，或达到预设最大迭代次数

3.3.7 K均值聚类

优势和局限性

- 优点
  - 算法逻辑简单
  - 计算效率高
  - 可解释性强
  - 目标函数单调非增
- 缺点
  - 必须预先指定K值
  - 对初始质心敏感
  - 偏好球形簇
  - 对异常值敏感



K均值聚类算法示意图

本章小结

- 机器学习是人工智能的核心分支，其本质是使计算机从数据中自主挖掘规律，并利用习得的规律对未知样本进行预测或决策。与传统编程的指令驱动范式不同，机器学习采用数据驱动范式，基于海量样本学习映射关系，在不确定场景中求解最优近似解。

- 在模型评估方面，泛化能力是衡量机器学习模型性能的核心指标。模型在训练集上的优异表现可能只是过拟合的表象，评判其性能优劣的关键是对未知数据的预测能力。

本章小结

- 在任务层面，机器学习可分为三大范式
  - 监督学习利用带标签数据学习输入到输出的映射关系，其中分类任务输出离散标签，回归任务输出连续数值。
  - 无监督学习在无标签数据中挖掘数据内在结构，聚类是其典型代表，旨在将相似样本自动分组。
  - 强化学习通过智能体与环境交互，依据奖惩反馈学习最优决策策略，三类范式共同构成完整的机器学习体系。

- 在经典算法层面，本章逐一介绍了七种经典算法，各类算法均具备独特的归纳偏好，在不同场景中适配不同任务，共同构成经典机器学习算法体系的坚实基石。

THANKS

